

Detecção de Fraudes em Transações Financeiras Utilizando Regressão Logística e LightGBM

Deoclécio Ivo de Melo Netto

Resumo—A detecção de fraudes em transações financeiras constitui um dos desafios mais críticos enfrentados por instituições bancárias e empresas do setor financeiro. O crescimento exponencial das transações digitais ampliou significativamente a superfície de ataque para atividades fraudulentas, tornando métodos tradicionais de monitoramento insuficientes para lidar com a complexidade, velocidade e volume dos dados atuais.

Nesse contexto, técnicas de Machine Learning emergem como ferramentas fundamentais para a identificação automática de padrões suspeitos, possibilitando a análise de grandes volumes de dados em tempo real. Entretanto, a aplicação desses métodos exige cuidados específicos, especialmente devido ao forte desbalanceamento entre as classes do problema — fraudes representam apenas uma pequena fração do total de transações.

Em cenários como esse, métricas tradicionais como acurácia podem ser enganosas, pois não refletem adequadamente a capacidade do modelo de identificar a classe minoritária. Erros de classificação possuem impactos distintos no contexto financeiro: falsos negativos, isto é, fraudes não detectadas, podem gerar perdas financeiras diretas e danos reputacionais significativos; por outro lado, falsos positivos, transações legítimas classificadas como fraudulentas, podem resultar em bloqueios indevidos, insatisfação de clientes e aumento de custos operacionais.

Dessa forma, torna-se essencial utilizar métricas mais adequadas para problemas desbalanceados, como Recall, Precision, F1-score e ROC-AUC. A ROC-AUC avalia a capacidade discriminativa do modelo independentemente de um limiar fixo, analisando o trade-off entre taxa de verdadeiros positivos e falsos positivos, oferecendo uma visão mais robusta do desempenho em cenários críticos.

Diante disso, este trabalho propõe a comparação de dois modelos de classificação supervisionada — Regressão Logística e LightGBM — com foco no tratamento do desbalanceamento, uso de métricas apropriadas, ajuste estratégico de threshold e análise de interpretabilidade, visando equilibrar desempenho preditivo e impacto operacional.

Index Terms—Detecção de Fraudes, Machine Learning, Desbalanceamento de Classes, Regressão Logística, LightGBM, ROC-AUC, XAI

I. INTRODUÇÃO

A detecção de fraudes em transações financeiras constitui um dos desafios mais críticos enfrentados por instituições bancárias e empresas do setor financeiro. O crescimento exponencial das transações digitais ampliou significativamente a superfície de ataque para atividades fraudulentas, tornando métodos tradicionais de monitoramento insuficientes para lidar com a complexidade, velocidade e volume dos dados atuais.

Nesse contexto, técnicas de Machine Learning emergem como ferramentas fundamentais para a identificação automática de padrões suspeitos, possibilitando a análise de grandes volumes de dados em tempo real. Entretanto, a aplicação desses métodos exige cuidados específicos, especialmente devido ao forte desbalanceamento entre as classes do problema

— fraudes representam apenas uma pequena fração do total de transações.

Em cenários como esse, métricas tradicionais como acurácia podem ser enganosas, pois não refletem adequadamente a capacidade do modelo de identificar a classe minoritária. Erros de classificação possuem impactos distintos no contexto financeiro: falsos negativos podem gerar perdas financeiras diretas e danos reputacionais significativos; falsos positivos podem resultar em bloqueios indevidos, insatisfação de clientes e aumento de custos operacionais.

Dessa forma, torna-se essencial utilizar métricas mais adequadas para problemas desbalanceados, como Recall, Precision, F1-score e ROC-AUC.

II. METODOLOGIA

A. Base de Dados e Pré-processamento

Foi realizada uma análise exploratória do dataset, composto por 28 variáveis preditoras anonimizadas (V1–V28) e uma variável alvo binária. Inicialmente, verificou-se a ausência de valores nulos e inconsistências estruturais.

A análise evidenciou forte desbalanceamento entre transações legítimas e fraudulentas, característica comum em problemas reais de detecção de fraudes.




Figura 1: Distribuição da variável V1 para as classes legítima (0) e fraudulenta (1).

Como ilustrado na Figura 1, observa-se diferença na distribuição da variável V1 entre as classes. A classe fraudulenta apresenta maior dispersão e concentração em faixas específicas de valores, indicando potencial poder discriminativo dessa feature para os modelos de classificação.

O conjunto `train.csv` foi dividido em treino e validação utilizando a estratégia *stratify*, preservando a proporção original das classes. Para mitigar o efeito do desbalanceamento,

utilizou-se `class_weight="balanced"`, ajustando os pesos das classes de forma inversamente proporcional à sua frequência.

Além da análise univariada, foi construída uma matriz de correlação utilizando o coeficiente de Pearson, a fim de investigar possíveis relações lineares entre as variáveis preditoras e a variável alvo.




Figura 2: Matriz de correlação entre as variáveis V1–V28 e a classe alvo.

Observa-se que as variáveis apresentam correlação próxima de zero entre si, indicando baixa multicolinearidade. Esse comportamento é esperado, pois as variáveis foram previamente transformadas por técnicas de redução de dimensionalidade (PCA).

Em relação à variável alvo, algumas features apresentam correlação moderada negativa, sugerindo possível relevância preditiva. Contudo, como a maioria das correlações é de baixa magnitude, justifica-se a utilização de modelos capazes de capturar relações não lineares, como o LightGBM.

B. Modelos Avaliados

Foram avaliados dois modelos de classificação supervisionada: Regressão Logística e LightGBM.

1) *Regressão Logística*: A Regressão Logística é um modelo linear probabilístico amplamente utilizado em problemas de classificação binária. Seu objetivo é modelar a probabilidade condicional da classe positiva por meio da função logística (sigmoide).

A probabilidade estimada é definida como:

$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta^T x)}} \quad (1)$$

onde:

- x representa o vetor de características;
- β são os coeficientes estimados;
- β_0 é o intercepto.

A decisão final é obtida comparando a probabilidade estimada com um limiar (threshold).

2) *LightGBM*: O LightGBM é um modelo baseado em Gradient Boosting Decision Trees, que constrói um conjunto de árvores de decisão de forma sequencial. A cada iteração, uma nova árvore é treinada para corrigir os erros do modelo anterior, otimizando uma função de perda de forma aditiva:

O modelo otimiza uma função de perda L adicionando árvores $f_t(x)$ de forma aditiva:

$$F(x) = \sum_{t=1}^T f_t(x) \quad (2)$$

onde cada nova árvore é ajustada ao gradiente negativo da função de perda.

C. Ajuste de Threshold

Em problemas desbalanceados, utilizar o limiar padrão de 0.5 pode não ser adequado. Assim, o threshold foi ajustado com base na curva Precision-Recall, que é mais informativa quando a classe positiva é rara. O critério adotado foi a maximização do F1-score, definido como:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (3)$$

A utilização da média harmônica penaliza valores muito discrepantes entre Precision e Recall, garantindo que o modelo apresente desempenho equilibrado tanto na identificação correta de transações fraudulentas quanto no controle de classificações incorretas.

No contexto deste trabalho, a maximização do F1-score permite encontrar um ponto de equilíbrio entre:

- Redução de falsos negativos (aumento do Recall), minimizando fraudes não detectadas e, consequentemente, perdas financeiras diretas;
- Controle de falsos positivos (manutenção da Precision), evitando bloqueios indevidos de transações legítimas e reduzindo impacto na experiência do cliente.

Essa estratégia é particularmente relevante em uma base composta por 28 variáveis preditoras e forte assimetria de classes, na qual a simples maximização da acurácia poderia favorecer excessivamente a classe majoritária e comprometer a efetividade operacional do sistema antifraude.

III. ANÁLISE DE ERROS E MÉTRICAS DE NEGÓCIO

Os modelos avaliados apresentaram desempenho semelhante na métrica ROC-AUC, ambos cerca de 97%, demonstrando boa capacidade de distinguir transações fraudulentas de legítimas.

Quanto ao Recall, a Regressão Logística apresentou 0,70, enquanto o LightGBM alcançou 0,73. Embora a diferença seja pequena, esse ganho representa maior número de fraudes detectadas, aspecto crítico em ambientes financeiros de alto volume transacional.

A Figura 3 apresenta a curva Precision-Recall para ambos os modelos, evidenciando o trade-off entre sensibilidade e precisão em diferentes limiares de decisão.

A análise detalhada dos erros pode ser observada nas matrizes de confusão apresentadas na Figura 4.




Figura 3: Curva Precision-Recall para Regressão Logística e LightGBM.




Figura 4: Matrizes de confusão para os modelos avaliados.

Observa-se que o LightGBM apresentou redução tanto na taxa de falsos positivos quanto na taxa de falsos negativos:

Regressão Logística

- Falsos Positivos: 0,022%
- Falsos Negativos: 0,050%

LightGBM

- Falsos Positivos: 0,0088%
- Falsos Negativos: 0,0461%

Essas reduções, embora percentualmente pequenas, possuem impacto financeiro significativo quando consideradas em larga escala, indicando melhor equilíbrio operacional do modelo baseado em boosting.

Essas reduções, embora percentualmente pequenas, possuem impacto financeiro significativo quando consideradas em larga escala, indicando melhor equilíbrio operacional do modelo baseado em boosting.

A. Diferença Estrutural na Tomada de Decisão

A Regressão Logística é um modelo linear discriminativo que assume uma relação aproximadamente linear entre as variáveis explicativas e o logaritmo da razão de chances (log-odds) da classe positiva. Por possuir menor complexidade estrutural e menor número de hiperparâmetros, tende a apresentar maior estabilidade e melhor capacidade de generalização quando as relações entre as 28 variáveis da base e o risco

de fraude são predominantemente lineares ou aproximadamente separáveis no espaço transformado. Além disso, sua natureza paramétrica favorece interpretabilidade, permitindo analisar diretamente o impacto individual de cada feature na probabilidade estimada de fraude.

Por outro lado, o LightGBM, baseado em Gradient Boosting com árvores de decisão, constrói o modelo de forma aditiva, capturando interações não lineares e relações complexas entre as variáveis. Em cenários de detecção de fraude, onde a classe minoritária frequentemente apresenta padrões sutis e combinações específicas de atributos, essa flexibilidade estrutural permite identificar regiões do espaço de características que não são linearmente separáveis. Como consequência, o modelo tende a melhorar a sensibilidade à classe fraudulenta e a ajustar melhor os limites de decisão, reduzindo levemente tanto falsos positivos quanto falsos negativos.

Enquanto a Regressão Logística oferece uma fronteira de decisão linear global, o LightGBM constrói múltiplas partições adaptativas no espaço das 28 features, permitindo modelar comportamentos heterogêneos e padrões locais da classe minoritária. Essa diferença estrutural explica o desempenho semelhante em métricas globais como ROC-AUC, mas com pequenas vantagens operacionais do LightGBM na matriz de confusão, especialmente na identificação de transações fraudulentas com características mais complexas.

IV. ANÁLISE DE INTERPRETABILIDADE (XAI)

A interpretabilidade é um fator crítico em aplicações financeiras, especialmente em sistemas de detecção de fraude, devido a exigências regulatórias, necessidade de auditoria e políticas de governança de dados. Modelos utilizados para tomada de decisão automatizada devem permitir rastreabilidade e justificativa técnica, principalmente quando suas decisões impactam diretamente clientes e operações bancárias.

No contexto deste trabalho, que utiliza uma base com 28 variáveis preditoras para estimar o risco de fraude de transações financeiras, a capacidade de explicar por que uma transação foi classificada como suspeita torna-se essencial para validação interna, conformidade regulatória e análise de contestação por parte do cliente.

A Regressão Logística possui interpretabilidade intrínseca, uma vez que seus coeficientes estimados estão diretamente associados à variação na probabilidade da classe positiva. Cada coeficiente indica a direção (aumento ou redução do risco) e a intensidade da influência de uma variável sobre a probabilidade de fraude, mantendo-se as demais constantes. Essa característica permite análise direta do impacto individual das variáveis e facilita a construção de relatórios técnicos e justificativas regulatórias.

Por outro lado, o LightGBM apresenta maior complexidade estrutural, pois é baseado em um conjunto aditivo de árvores de decisão treinadas sequencialmente via gradient boosting. A interação não linear entre variáveis e a construção hierárquica das árvores dificultam a interpretação direta dos parâmetros do modelo. Dessa forma, são necessárias técnicas pós-hoc para compreensão das decisões, como análise de importância de variáveis (*feature importance*) ou métodos baseados em

valores de Shapley, como SHAP, que permitem estimar a contribuição individual de cada atributo para uma predição específica.

Assim, observa-se um trade-off clássico entre desempenho preditivo e interpretabilidade: enquanto o LightGBM tende a capturar padrões complexos e interações não lineares presentes na classe minoritária, a Regressão Logística oferece maior transparência estrutural e facilidade de explicação, aspecto particularmente relevante em ambientes financeiros regulados.

A. Importância das Variáveis

A análise de importância das variáveis permite compreender quais atributos mais influenciaram as decisões dos modelos, contribuindo para maior transparência e interpretabilidade.

A Figura 5a apresenta os coeficientes estimados pela Regressão Logística. Como se trata de um modelo linear, os coeficientes indicam a direção e a intensidade da influência de cada variável na probabilidade de fraude. Coeficientes positivos aumentam a probabilidade da classe fraudulenta, enquanto coeficientes negativos reduzem essa probabilidade.

Observa-se que variáveis como V22 e V4 apresentam forte contribuição positiva, enquanto V14 e V10 possuem contribuição negativa relevante. A interpretação é direta: quanto maior o valor dessas variáveis, maior (ou menor) a chance estimada de fraude, dependendo do sinal do coeficiente.

Já a Figura 5b apresenta a importância das variáveis segundo o LightGBM, medida pelo ganho acumulado (gain) nas divisões das árvores. Nota-se que a variável V14 possui importância significativamente superior às demais, indicando que ela é altamente discriminativa para a detecção de fraudes no modelo baseado em árvores.

Diferentemente da Regressão Logística, o LightGBM captura interações não lineares entre variáveis. Isso explica a concentração de importância em determinadas features que, em conjunto com outras, produzem maior separação entre as classes.

Comparando os modelos, percebe-se que ambos identificam algumas variáveis relevantes em comum (como V14), porém o LightGBM distribui a importância de forma mais concentrada, enquanto a Regressão Logística apresenta influência mais distribuída entre múltiplas variáveis.

Essa análise reforça que, embora o LightGBM tenha apresentado melhor desempenho operacional, a Regressão Logística oferece maior transparência estrutural, o que pode ser desejável em contextos regulatórios.

V. CONCLUSÃO

Este trabalho avaliou os modelos Regressão Logística e LightGBM aplicados à detecção de fraudes em transações financeiras, considerando explicitamente o desbalanceamento entre classes, o ajuste estratégico do threshold e o impacto operacional dos erros de classificação em ambientes bancários de alto volume transacional.

Ambos os modelos apresentaram elevada capacidade discriminativa, com valores de ROC-AUC próximos a 97%, indicando forte separabilidade entre transações fraudulentas e legítimas. Entretanto, a análise detalhada da matriz de confusão evidenciou diferenças relevantes sob a perspectiva de negócio. O LightGBM apresentou redução tanto na taxa de falsos positivos quanto na taxa de falsos negativos, demonstrando melhor equilíbrio entre sensibilidade e precisão.

Do ponto de vista operacional, a redução de falsos negativos implica menor ocorrência de fraudes não detectadas, mitigando perdas financeiras diretas e riscos reputacionais. Simultaneamente, a diminuição de falsos positivos reduz bloqueios indevidos de transações legítimas, contribuindo para melhor experiência do cliente e menor custo operacional.

Por outro lado, a Regressão Logística oferece maior interpretabilidade estrutural, permitindo análise direta da influência de cada variável na probabilidade estimada de fraude. Esse aspecto é particularmente relevante em contextos regulatórios, nos quais transparência e auditabilidade das decisões automatizadas são requisitos fundamentais.

Conclui-se, portanto, que o LightGBM apresenta melhor desempenho sob a ótica operacional e de impacto financeiro, enquanto a Regressão Logística se destaca pela simplicidade e interpretabilidade. A escolha do modelo ideal depende do equilíbrio desejado entre desempenho preditivo e requisitos regulatórios, evidenciando o trade-off clássico entre performance e explicabilidade em sistemas de Machine Learning aplicados ao setor financeiro.




Figura 5: Importância das variáveis segundo os modelos avaliados.